

Cahier des Charges

CAHIER DES CHARGES

Global Phosphate Market Analytics Platform

Data Engineering & Data Analytics — Plateforme d'analyse
prédiction
du marché mondial du phosphate

 Juillet 2026
•
 Projet Fil Rouge
•
 Deadline 08/08/2026

```
<div class="stack-item"><span class="ico"> </span>Python</div>  
<div class="stack-item"><span class="ico"> </span>Snowflake</div>  
  <div class="stack-item"><span class="ico"> </span>dbt</div>  
<div class="stack-item"><span class="ico"> </span>Power BI</div>  
<div class="stack-item"><span class="ico"> </span>Airflow</div>  
  <div class="stack-item"><span class="ico"> </span>MinIO</div>  
<div class="stack-item"><span class="ico"> </span>Docker</div>  
  <div class="stack-item"><span class="ico"> </span>ML</div>
```

Sommaire

02	Présentation du projet
03	Contexte métier
04	Objectifs
05	Périmètre du projet
06	Architecture globale
07	Architecture technique détaillée
08	Architecture Medallion
09	Technologies utilisées
10	Flux de données
11	Description des couches
12	Modèle dimensionnel
13	Pipeline complet
14	Machine Learning
15	Dashboard Power BI
16	Orchestration Airflow
17	Structure des dossiers
18	Planning du projet
19	Analyse des risques
20	Critères de réussite
21	Livrables

22 Évolutions futures

23 Conclusion

2. Présentation du projet

En une phrase : Une plateforme end-to-end qui collecte, structure et prédit les dynamiques du marché mondial du phosphate pour éclairer la décision stratégique.

Élément	Détail
Nom du projet	Global Phosphate Market Analytics Platform
Type	Projet Fil Rouge — Data Engineering / Data Analytics
Domaine	Marché des matières premières — Phosphate
Nature	Pipeline ELT + Data Warehouse + ML + BI
Échéance	08/08/2026

3. Contexte métier

Le phosphate est une ressource stratégique pour l'agriculture mondiale (engrais), sous tension géopolitique et économique croissante. Les décideurs (industriels, investisseurs, institutions) manquent d'un outil unifié croisant **prix, production, échanges commerciaux et indicateurs macroéconomiques**.

Callout – Enjeu métier Sans consolidation de ces données dispersées, l'analyse du marché reste fragmentée, réactive, et peu prédictive.

Sources de données mobilisées




Diagramme 0

4. Objectifs

Objectif	Description
O1 — Centraliser	Unifier 4 sources hétérogènes dans un Data Lake puis un Data Warehouse
O2 — Fiabiliser	Garantir qualité, cohérence et traçabilité des données (tests dbt)
O3 — Prédire	Anticiper l'évolution des prix du phosphate (2024-2026) via Machine Learning
O4 — Visualiser	Fournir un dashboard exécutif interactif et décisionnel
O5 — Automatiser	Orchestrer l'ensemble du pipeline sans intervention manuelle (Airflow)

5. Périmètre du projet

Inclus dans le projet - Extraction automatisée (scraping + API) des 4 sources - Data Lake MinIO + Data Warehouse Snowflake (Bronze/Silver/Gold) - Transformations dbt avec tests de qualité - Modèle de prévision des prix (ML) - Dashboard Power BI exécutif - Orchestration Airflow bout en bout

Hors périmètre - Développement d'une application web front-end dédiée - Trading algorithmique en temps réel - Couverture de matières premières autres que le phosphate

6. Architecture globale




Diagramme 1

7. Architecture technique détaillée




Diagramme 2

Détail des couches techniques

Couche	Rôle	Outils
Extraction	Scraping & appels API	Python, Requests, BeautifulSoup, Selenium
Stockage brut	Data Lake objet	MinIO
Entrepôt	Bronze / Silver / Gold	Snowflake, dbt Core
Prédiction	Modélisation prix	Scikit-Learn
Restitution	Dashboards	Power BI
Orchestration	Automatisation	

Couche	Rôle	Outils
		Apache Airflow, Docker
Versioning	Code & collaboration	Git, GitHub, VS Code

8. Architecture Medallion




Diagramme 3

Couche	Contenu	Traitements
Bronze	Copie fidèle des sources	Aucun – traçabilité brute
Silver	Données propres	Suppression doublons, gestion des valeurs manquantes, normalisation, tests dbt
Gold	Modèle analytique	Star Schema, tables de faits, dimensions, KPIs métier

9. Technologies utilisées

Catégorie	Technologies
Langage & Extraction	Python · Pandas · Requests · BeautifulSoup · Selenium
Stockage	MinIO
Entrepôt de données	Snowflake
Transformation	dbt Core
Conteneurisation	Docker
Orchestration	Apache Airflow
Machine Learning	Scikit-Learn
Visualisation	Power BI
Versioning	Git · GitHub · VS Code

10. Flux de données




Diagramme 4

11. Description de chaque couche

Bronze — Ingestion brute depuis MinIO vers Snowflake, sans altération, pour garantir la traçabilité complète des données sources.

Silver — Application des règles de qualité : suppression des doublons, traitement des valeurs manquantes, normalisation des formats (dates, unités, devises), exécution des tests dbt (`not_null` , `unique` , `relationships`).

Gold — Construction du modèle dimensionnel orienté analyse : tables de faits (prix, production, échanges) reliées aux dimensions (temps, pays, produit).

12. Modèle dimensionnel




Diagramme 5

13. Pipeline complet




Diagramme 6

.

14. Machine Learning

Élément	Détail
Objectif	Prévision des prix du phosphate
Horizon	2024 · 2025 · 2026
Approche	Régression / séries temporelles (Scikit-Learn)
Données d'entrée	Table de faits Gold (historique prix, production, macro-économie)
Sortie	Prix prédit injecté dans le dashboard Power BI



Diagramme 7

15. Dashboard Power BI

Dashboard Exécutif – vue synthétique et décisionnelle du marché mondial du phosphate.

Page	Contenu
Vue d'ensemble	KPIs clés, tendance globale
Prix	Évolution historique et prévisionnelle
Production	Analyse par pays et par période
Import	Volumes et tendances par pays
Export	Volumes et tendances par pays
Comparaison pays	Benchmark des principaux producteurs
Prévisions	Résultats du modèle ML
Insights	Synthèse des enseignements clés

16. Orchestration Airflow



Diagramme 8

Tâche Airflow	Fréquence
Extraction & ingestion	Quotidienne / hebdomadaire selon la source
Transformation dbt	À chaque nouvelle donnée
Entraînement ML	Mensuelle
Refresh Power BI	À chaque fin de pipeline
Notifications	Succès / échec de chaque run

17. Structure des dossiers

```
global-phosphate-analytics/  
├── extraction/  
│   ├── indexmundi_scraper.py  
│   ├── faostat_extractor.py  
│   ├── comtrade_extractor.py  
│   └── worldbank_extractor.py  
├── .dbt_project/  
│   ├── models/  
│   │   ├── bronze/  
│   │   ├── silver/  
│   │   └── gold/  
│   └── tests/  
├── .ml/  
│   ├── train_model.py  
│   └── predict.py  
├── airflow/  
│   └── dags/  
│       └── phosphate_pipeline_dag.py  
├── powerbi/  
│   └── dashboard.pbix  
├── docker/  
│   └── docker-compose.yml  
└── README.md
```

18. Planning du projet




Diagramme 9

19. Analyse des risques

Risque	Impact	Probabilité	Mitigation
Données 2026 incomplètes chez les sources	Moyen	Élevée	Recours au forecast ML au-delà des données réelles disponibles
Instabilité des sites scrapés	Moyen	Moyenne	Scripts robustes + gestion d'erreurs + Selenium en secours
Délai serré (deadline 08/08/2026)	Élevé	Moyenne	Planning strict, priorisation des livrables critiques
Qualité hétérogène entre sources	Moyen	Élevée	Tests dbt systématiques en couche Silver
Complexité de l'orchestration Airflow	Faible	Moyenne	Tests progressifs par tâche avant intégration complète

20. Critères de réussite

Pipeline end-to-end fonctionnel de l'extraction jusqu'au dashboard
Données Bronze/Silver/Gold cohérentes et testées
Modèle ML produisant des prévisions exploitables (2024–2026)
Dashboard Power BI clair, interactif et orienté décision
Orchestration Airflow autonome et fiable
Documentation complète et professionnelle du projet

21. Livrables

Livrable	Format
Scripts d'extraction	Python (.py)
Data Lake	MinIO (buckets)
Data Warehouse	Snowflake (Bronze/Silver/Gold)
Projet dbt	Modèles + tests
Modèle ML	Script + artefact de prédiction
Dashboard	Power BI (.pbix)
Orchestration	DAG Airflow
Documentation	Cahier des charges (ce document) + README

22. Évolutions futures

- Ajout de nouvelles matières premières (potasse, azote)
- API publique d'exposition des données consolidées
- Modèles ML avancés (deep learning, séries temporelles multivariées)
- Migration complète vers une orchestration cloud managée

23. Conclusion

Global Phosphate Market Analytics Platform structure une chaîne de valeur data complète — de la donnée brute dispersée à l'insight décisionnel — au service d'une meilleure compréhension du marché mondial du phosphate.

Document réalisé dans le cadre du projet Fil Rouge — Data Engineering & Data Analytics