

TECHNICAL DOCUMENTATION

Global Phosphate Market Analytics Platform

Data Engineering · Data Lake · Data Warehouse · Machine
Learning · Business Intelligence

v2.0

Deadline
08/08/2026

Projet Fil
Rouge

Python

MinIO

Snowflake

dbt

ML

Power BI

Airflow

Docker

NAVIGATION

Sommaire

01	Executive Summary	02	Contexte métier
03	Objectifs	04	Périmètre
05	Architecture globale	06	Architecture détaillée
07	Architecture Medallion	08	Stack technique
09	Flux de données	10	Modèle dimensionnel
11	Pipeline complet	12	Machine Learning
13	Dashboard Power BI	14	Orchestration Airflow
15	Structure des dossiers	16	Planning
17	Analyse des risques	18	Critères de réussite
19	Livrables	20	Roadmap & Conclusion

01 · OVERVIEW

Executive Summary

Plateforme end-to-end de collecte, structuration et prédiction du marché mondial du phosphate — pensée décision, pas juste reporting.

4
SOURCES DE DONNÉES

3
COUCHES MEDALLION

9
TECHNOLOGIES

08/08
DEADLINE 2026

Mission
Centraliser prix, production, échanges et macro-éco du phosphate dans un entrepôt unique.

Prédiction
Modèle ML de prévision des prix sur l'horizon 2024–2026.

Décision
Dashboard Power BI exécutif pour les parties prenantes métier.

En bref — Python extrait 4 sources hétérogènes → MinIO (lake) → Snowflake Bronze/Silver/Gold (dbt) → Machine Learning → Power BI, le tout orchestré par Airflow.

ELTStar SchemaForecast MLOrchestrationCloud DWH

02 · BUSINESS CONTEXT

Contexte métier

Le phosphate est une ressource stratégique pour l'agriculture mondiale — l'enjeu est l'accès à une vision consolidée du marché.

Ressource stratégique

Le phosphate est un intrant clé des engrais agricoles mondiaux.

Marché fragmenté


Prix, production et échanges sont dispersés sur des sources non connectées.

Décideurs multiples

Industriels, investisseurs, institutions ont besoin d'un référentiel commun.

Manque de prédictif

Sans consolidation, l'analyse reste réactive plutôt qu'anticipative.



MINDMAP — Sources de données par thématique

03 · GOALS

Objectifs



5 objectifs mesurables pilotent l'ensemble du projet.

01 — Centraliser

Unifier 4 sources hétérogènes : Data Lake → Data Warehouse.

02 — Fiabiliser

Garantir qualité et traçabilité via des tests dbt systématiques.

03 — Prédire

Anticiper les prix du phosphate 2024–2026 via Machine Learning.

04 — Visualiser

Fournir un dashboard exécutif interactif et actionnable.

05 — Automatiser

Orchestrer le pipeline bout-en-bout, sans intervention manuelle.

Success metric

Pipeline autonome + dashboard livré avant le 08/08/2026.

04 · SCOPE

Périmètre du projet

Ce qui est livré — et ce qui ne l'est volontairement pas.

✓ Inclus

- ✓ Extraction automatisée (scraping + API) des 4 sources
- ✓ Data Lake MinIO + Data Warehouse Snowflake
- ✓ Transformations dbt avec tests de qualité
- ✓ Modèle de prévision des prix (ML)
- ✓ Dashboard Power BI exécutif
- ✓ Orchestration Airflow bout-en-bout

✗ Hors périmètre


- ✗ Application web front-end dédiée
- ✗ Trading algorithmique temps réel
- ✗ Autres matières premières que le phosphate
- ✗ Infrastructure cloud production multi-région

Contrainte donnée — Données réelles disponibles 2016–2025 (annuel) + Jan–Mar 2026 (USA, mensuel) ; au-delà : forecast ML uniquement.

05 · ARCHITECTURE

Architecture globale

De la source brute au dashboard décisionnel, orchestré bout-en-bout.



Python

MinIO

Snowflake

dbt

ML

Power BI


Airflow

Design principle — Chaque couche est indépendante et testable ; Airflow orchestre sans coupler les technologies entre elles.

06 · TECHNICAL DEEP-DIVE

Architecture technique détaillée

Chaque bloc correspond à un composant déployable indépendamment.



Couche	Rôle	Outils
Extraction	Scraping & appels API	Python · Requests · BeautifulSoup · Selenium
Stockage brut	Data Lake objet	MinIO
Entrepôt	Bronze / Silver / Gold	Snowflake · dbt Core


Prédiction	Modélisation prix	Scikit-Learn
Restitution	Dashboards	Power BI
Orchestration	Automatisation	Airflow · Docker

07 · DATA MODEL

.

Architecture Medallion

Bronze → Silver → Gold : un pipeline de qualité progressive.



08 · TECH STACK

Stack technique

9 technologies, chacune avec un rôle précis dans la chaîne de valeur.



Python

Extraction & scripting

Core



MinIO

Data Lake objet

Storage



Snowflake

Data Warehouse cloud

DWH



dbt Core

Transformation & tests

ELT



Airflow

Orchestration

DAG



Docker

Conteneurisation

Infra



Scikit-Learn

Machine Learning

ML



Power BI

Visualisation

BI




Git / GitHub

Versioning

VCS


Flux de données

Séquence complète, du déclenchement Airflow jusqu'à la notification finale.



Modèle dimensionnel

Star Schema : 1 table de faits, 3 dimensions.




DIM_DATE
Année, mois, trimestre

DIM_COUNTRY
Pays, région, producteur majeur

DIM_INDICATOR
Type d'indicateur, source, unité

Pipeline complet

De l'extraction au dashboard, avec gestion d'échec intégrée.



FLOWCHART — Pipeline avec contrôle qualité



12 · MACHINE LEARNING

Machine Learning

Prévision des prix du phosphate sur l'horizon 2024–2026.

3



ANNÉES PRÉVUES

ML

SCIKIT-LEARN

Gold

SOURCE DES FEATURES



Dashboard Power BI

Un dashboard exécutif organisé en 8 vues, orienté décision.



Vue d'ensemble

KPIs clés & tendance globale



Prix

Évolution historique & prévisionnelle



Production

Analyse par pays et période



Import

Volumes et tendances par pays



Export

Volumes et tendances par pays



Comparaison pays

Benchmark producteurs majeurs



Prévisions

Résultats du modèle ML




Insights

Synthèse des enseignements clés

14 · ORCHESTRATION

Orchestration Airflow

Un DAG unique automatise l'ensemble de la chaîne, sans intervention manuelle.



Tâche	Fréquence
Extraction & ingestion	Quotidien / Hebdo
Transformation dbt	À chaque nouvelle donnée
Entraînement ML	Mensuel
Refresh Power BI	Fin de pipeline
Notifications	Succès / Échec

15 · REPOSITORY

Structure des dossiers


Organisation du repo GitHub du projet.

```
global-phosphate-analytics/  
├── extraction/  
│   ├── indexmundi_scraper.py  
│   ├── faostat_extractor.py  
│   ├── comtrade_extractor.py  
│   └── worldbank_extractor.py  
├── dbt_project/  
│   ├── models/{bronze,silver,gold}/  
│   └── tests/  
├── ml/  
│   ├── train_model.py  
│   └── predict.py  
├── airflow/dags/phosphate_pipeline_dag.py  
├── powerbi/dashboard.pbix  
├── docker/docker-compose.yml  
└── README.md
```

16 · TIMELINE

Planning du projet

6 jalons entre cadrage et livraison finale.



- 20–22 JUIL.
Cadrage & cahier des charges
- 23–27 JUIL.
Extraction & ingestion MinIO
- 28 JUIL–03 AOÛT
Snowflake Bronze → Silver → Gold
- 04–05 AOÛT
Machine Learning & Power BI
- 06 AOÛT
Airflow & tests bout-en-bout
- 08 AOÛT
Livraison finale

17 · RISK MATRIX

Analyse des risques

5 risques positionnés sur impact × probabilité.



QUADRANT CHART — Impact vs Probabilité

Risque	Niveau	Mitigation
Données 2026 incomplètes	Élevé	Recours au forecast ML
Délai serré (08/08/2026)	Élevé	Planning strict, priorisation
Qualité hétérogène entre sources	Moyen	Tests dbt systématiques
Instabilité des sites scrapés	Moyen	Scripts robustes + Selenium
Complexité orchestration Airflow	Faible	Tests progressifs par tâche

18 · SUCCESS CRITERIA

.

Critères de réussite

6 conditions de livraison validées.

Pipeline end-to-end fonctionnel

Bronze/Silver/Gold cohérents et testés

Modèle ML exploitable (2024–2026)

Dashboard clair et orienté décision

Orchestration Airflow autonome

Documentation complète & professionnelle

19 · DELIVERABLES

Livrables

Dashboard de suivi des livrables du projet.

Scripts d'extraction

Python

.py

Data Lake

MinIO

Buckets

Data Warehouse

Snowflake

Bronze/Silver/Gold

Projet dbt

dbt Core

Modèles + tests

Modèle ML

Scikit-Learn

Script + artefact

Dashboard

Power BI

.pbix

Orchestration

Airflow

DAG

Documentation


Cahier + README

MD / PDF


20 · ROADMAP

Évolutions futures & Conclusion


Ce que la plateforme peut devenir après la V1.



TIMELINE — Roadmap produit



PIE CHART — Répartition de l'effort projet



Conclusion — Global Phosphate Market Analytics Platform transforme une donnée dispersée en insight décisionnel, avec une chaîne data complète, testée et automatisée.